

AI简历优化助手-模型选型对比分析报告

文档版本：v1.0 | 编写日期：2026-05-06 | 适用产品版本：AI简历优化助手 v1.0

文档性质：产品侧模型选型决策文档

一、报告目的

AI简历优化助手的核心价值链路是：

上传简历 → 解析提取 → JD采集 → 关键词提取与对比 → 匹配分析(0-100%) → AI优化(整体/模块) → 双栏优化前后对比 → 模拟面试题生成 → 一键导出

这条链路里，除了文件解析和评分展示，几乎每一个环节都要调用大模型。模型的选择直接决定三件事：

- 1. 优化质量——简历改得好不好、面试题靠不靠谱，是产品口碑的地基；
- 2. 响应体验——用户点「一键优化」后要等多久，直接影响留存与转化；
- 3. 单位成本——每一次优化都在烧 Token，直接决定 29 元/月会员这门生意能不能算得过账。

模型选型是一个「质量 × 体验 × 成本」的三角权衡问题。

二、先拆需求：不同功能对模型的要求并不一样

选型的第一步是把功能按「对模型能力的要求」重新归类。我把 v1.0 的 AI 相关功能拆成三档：

能力档位	涉及功能（对应 FeatureList 编号）	对模型的核心要求	调用频率
A. 结构化理解 / 抽取	简历解析提取(F1-2)、关键词提取与对比(F3-1)、匹配分析0-100%(F3-2)	稳定、可控、能吐结构化 JSON；对创造力要求低，对一致性和格式遵循要求高	高频
B. 复杂生成 / 改写	AI优化整体/模块(F2-2)、差距分析报告(F3-3)	语言质量高、懂行业表达、能按策略改写；这是产品核心卖点，质量优先	高频
C. 发散生成	模拟面试题生成(F4-1, P1)	内容合理、覆盖面广即可，容错空间大	中低频

不该用同一个模型硬扛所有功能。

三、候选模型对比

3.1 候选池

模型	厂商	定位	中文能力	结构化输出	相对成本	备注
GPT-4o / GPT-4.1	Open AI	综合能力标杆	强	强（原生 JSON mode）	高	国内直连需处理网络与合规
Claude 系列	Anthropic	长文本 / 写作质量强	强	强	高	长简历+长JD场景友好，同样有国内接入问题
DeepSeek-V3 / R1	深度求索	高性价比、中文强	很强	强	很低	国内可直连、备案合规、价格极低，推理版R1适合复杂改写
通义千问 Qwen-Max/Plus	阿里	国内生态成熟	很强	强	中低	阿里云一站式，企业级稳定性好
文心一言 ERNIE	百度	国内老牌	强	中	中	生态成熟，中文语料充足
GLM-4 系列	智谱	国产、Agent 能力强	强	强	低	文档友好，个人开发者接入门槛低

3.2 关键维度评估

维度	说明	权重	谁更占优
中文简历/JD理解	中文语料质量、对国内岗位术语的理解	★★★★★	DeepSeek / Qwen / 文心
改写与写作质量	简历优化是核心卖点，语言要专业不假大空	★★★★★	Claude / GPT / DeepSeek-R1
结构化输出稳定性	匹配分析、关键词对比要吐可解析的 JSON	★★★★	GPT / Qwen / DeepSeek
单次调用成本	直接决定29元会员的毛利	★★★★★	DeepSeek / GLM / Qwen
响应延迟	影响「一键优化」的体验	★★★★	各家轻量版接近

合规与国内可用性	面向国内求职者，必须能稳定备案直连	★★★★★	DeepSeek / Qwen / 文心 / GLM
----------	-------------------	-------	----------------------------

四、选型结论：分层调用，而非单选

按能力档位做**分层调用（Model Routing）**：

功能档位	推荐主模型	备选	选型理由
A. 解析/关键词/匹配打分	DeepSeek-V3 或 Qwen-Plus	GLM-4	任务确定、要求稳，用性价比模型即可，把成本压到最低
B. 简历优化/差距报告	DeepSeek-R1 或 Qwen-Max	Claude（若面向海外/高端付费）	核心卖点，质量优先；R1的推理能力对「按策略改写」帮助大
C. 模拟面试题	DeepSeek-V3	GLM-4	容错高、频率低，用便宜快的即可

「面向国内求职者的中文场景，DeepSeek 在**中文能力、结构化输出、合规直连、极低成本**四个我最看重的维度上同时占优；核心的简历改写用推理版保质量，高频的解析打分用基础版控成本，形成质量与成本的平衡。」

五、成本测算（这是产品经理最该算的账）

以「一次完整优化」为一个计费单元，粗估单次消耗：

- 输入：简历(约1500字) + JD(约800字) + Prompt模板 $\approx$ 3000–4000 tokens
- 输出：优化全文 + 匹配分析 + 关键词 $\approx$ 2000–3000 tokens
- 单次总量约 **6000–7000 tokens**

对比同样一次调用，用高价海外模型 vs 用 DeepSeek，**单次成本可能相差一个数量级**。这直接关系到：

- 免费版给几次额度不亏本（FeatureList 里免费版是「带水印或限制次数」）；
- 29元/月会员的毛利空间有多大；
- 单用户月活优化次数的盈亏平衡点在哪。

产品结论：用分层调用把高频低价值环节（解析/打分）的成本压到最低，把预算集中在低频高价值环节（改写），是让 29 元会员算得过账的关键。

六、落地风险与应对

风险	说明	应对策略
单一供应商依赖	模型限流、涨价、服务波动会直接打断业务	抽象统一的模型调用层，DeepSeek 为主、Qwen 为备，可一键切换
输出不稳定	结构化字段偶尔解析失败	强制 JSON schema + 失败重试 + 兜底解析；Prompt 迭代
长简历超上下文	部分简历+JD过长	优先选长上下文模型处理B档，或做分段摘要
合规与隐私	简历含大量个人信息（PII）	选国内备案模型；传输加密；对手机号等敏感字段脱敏后再入模型
成本失控	用户滥用一键优化	免费版限次、结果缓存、相同JD复用