

AI简历优化助手 - Prompt 迭代记录表

文档作者：王彤
所属项目：AI简历优化助手
迭代周期：2026年1月 - 2026年3月
文档版本：V1.0
最后更新：2026年7月10日

一、文档概述

本文档记录了“AI建立优化助手”项目中Prompt策略从V0.1到V0.4的完整迭代过程，包括每一轮的Prompt设计思路、测试数据、Bad Case分析和改进决策。

一、迭代概况

维度	数据
Prompt 策略数量	4 类（STAR 改写 / 关键词植入 / 动词强化 / 量化补充）
迭代轮次	4 轮
迭代周期	2026年1月 - 2026年3月（约12周）
测试样本总量	50+ 条简历片段（覆盖技术、产品、运营、设计四类岗位）
评估人员	3人（本人 + 2名正在求职的同学）
评估方式	人工抽检（本人 + 2 名同学交叉评估）
评估标准	可用率 = 修改后可被用户直接采用或仅需微调的比例
初始准确率	62%（V0.1，仅基础 Prompt，无策略拆分）
最终准确率	89%（V0.4，4 类策略独立调优 + 质量自检）

各版本指标

版本	时间	可用率	部分可用	不可用	核心改进	遗留问题
----	----	-----	------	-----	------	------

V0.1	1月上旬	62%	25%	15%	--	编造实时、无效改写
V0.2	1月中旬	74%	15%	10%	策略拆分、角色设定、输出格式约定	输出模版化
V0.3	2月上旬	83%	12%	4%	策略独立调优、行业语境、动词分级	量化补充力度难把控
V0.4	2月下旬-3月	89%	8%	4%	质量自检、Few-shot对比示例	量化补充（80%）仍需突破

二、评估标准说明

每轮从测试样本池中随机抽取 20 -25 条，由 3 名评估者（本人 + 2 名正在求职的同学）独立打分，取均值。

评分	标准	含义	用户感知
✅ 可用	修改结果可直接采用，或仅需 < 20% 微调	合格	“AI改的不错，我可以直接使用”
⚠️ 部分可用	方向正确但需要 20-50% 修改	不合格	“方向对，但是我还得改不少地方”
❌ 不可用	偏离原意、编造事实、格式混乱	不合格	“这改的是什么，还不如我自己写”

准确率 = 可用数 / 总测试样本数 × 100%

评估局限性说明

局限	说明	缓解措施
样本量有限（50+）	无法覆盖所有行业和岗位	V1.0上线后通过用户行为数据补充
评估者主观性	“可用 vs 部分可用” 边界模糊	3人交叉评估 + 一致性校验
无真实用户反馈	评估者 ≠ 真实用户	V1.0计划埋点追踪采纳率
未区分岗位类型	技术/产品/运营/设计 混评	V1.1计划按岗位维度分析准确率

三、逐轮迭代记录

第 1 轮：V0.1 — 基础版（统一 Prompt）

时间： 2026年1月上旬

目标： 验证 LLM 是否具备简历优化能力

做法： 用一条通用 Prompt 处理所有类型的简历内容

Prompt 设计

代码块

1

你是一位专业的简历优化顾问。请帮我优化以下简历内容，让它更专业、更有吸引力。

2

3

【原始内容】

4

{用户输入的简历片段}

设计思路： 最小可行 Prompt——仅给出角色和任务，不附加任何约束。目的是先看清 LLM 在"无约束"状态下的行为模式，为后续约束设计提供依据。

测试结果

指标	数据	分析
测试样本数	20 条	—
✅ 可用	12 条（60%）→ 取整 62%	没有达到产品的可用标准
⚠️ 部分可用	5 条（25%）	主要问题：方向对单需要大量修改
❌ 不可用	3 条（15%）	集中于 “编造数据” 和 “偏离原意”

典型 Bad Case

原始内容	AI输出	问题分析	问题类型
“负责产品的用户调研工作”	“主导了大规模用户调研项目，通过问卷调查和深度访谈收集了超过1000份有效反馈，为产品迭代提供了数据驱动的决策依据”	编造了数字（1000份），用户实际只做了几十份调研	● 编造事实
“参与公司微信公众号运营”	“负责公司新媒体矩阵运营，包括微信公众号、小红书、知乎等平台，月均涨粉5000+”	扩大了工作范围（多平台），编造了涨粉数据	● 偏离事实

“用Excel做数据统计”	“运用Excel进行数据统计分析”	只是换了一种说法，没有实质优化	● 无效改写
“写了产品需求需求文档”	“撰写了产品需求文档（PRD）”	加了括号解释但内容无实质变化	● 优化幅度小

问题根因分析

核心矛盾：LLM 的"讨好型人格"

表现1：为了回答显得"有用"，倾向添加具体细节 → 编造数字

表现2：为了回答显得"专业"，倾向使用高级词汇 → 过度拔高

表现3：隐含假设"用户希望我多写一些" → 扩大工作范围

根因：Prompt 中没有任何"不做某事"的约束，LLM 默认行为是"积极作为"

本轮结论

发现	影响	行动
LLM有能力做简历优化，62%的内容可以接受	验证了产品的可行性	继续迭代
通过Prompt产生两大问题： 编造事实 和 无效改写	直接影响用户信任	必须拆分策略，再加入反编造约束
用户不会分辨AI输出的好坏	产品风险：坏输出会直接流失用户	系统需要替用户做质量把关

第 2 轮：V0.2 — 策略拆分 + 约束强化

时间：2026年1月中旬

目标：拆分 4 类策略，加入角色设定和输出格式约束，解决编造问题

做法：为 4 种优化场景分别设计 Prompt，加入角色设定 + 输出格式模板

策略拆分逻辑

- 用户简历优化需求
- 策略1：STAR 改写 — 将流水账式描述改写为 STAR（情境-任务-行动-结果）结构；
适用：实习经历、项目经历等有过程有结果的场景。
 - 策略2：关键词植入 — 根据目标 JD 在简历中自然融入行业关键词；
适用：JD 匹配场景，提升 ATS（Applicant Tracking System）通过率。

- 策略3：动词强化 — 用更具行动力和专业感的动词替换弱动词；
适用：所有动作性描述。
- 策略4：量化补充 — 在可量化维度上提示补充数据，但以"提示"代替"编造"；
适用：有可量化空间但原文缺乏数据的场景。

Prompt 设计（以 STAR 改写为例）

```
代码块
1  # 角色设定
2  你是一位资深的简历优化顾问，专注于帮助求职者将平淡的经历描述改写为STAR（情境-任务-行动-结果）结构的
3  专业表达。
4
5  # 核心原则（必须遵守）
6  1. 【严禁编造】所有改写必须基于原文提供的事实信息，不得添加原文中不存在的数字、项目名称、团队规模等
7  2. 【保留真实】如果原文没有量化数据，不要编造，而是用 [请补充：具体数字] 标记缺失的量化维度
8  3. 【识别语境】根据上下文判断用户所在的行业和岗位，使用恰当的行业用语
9
10 # 输出格式
11 请按以下格式输出：
12  【优化后】<改写后的STAR结构内容>
13  【改动说明】<逐条说明做了什么改动及原因>
14  【需要补充】<如果有缺失的关键信息，提示用户补充什么>
15
16 # 原始内容
17  {用户输入的简历片段}
```

测试结果

指标	数据	Vs V0.1
测试样本数	20条	—
✅ 可用	15 条 → 74%	↑ 12%
⚠️ 部分可用	3 条 (15%)	↓ 10%
❌ 不可用	2 条 (10%)	↓ 5%

改进效果

--	--	--	--	--

问题类型	V0.1出现次数	V0.2出现次数	变化	分析
编造事实	5	1	✅ 大幅减少	"严禁编造"约束生效
无效改写	4	2	✅ 改善	输出格式引导了深度改写
格式混乱	2	1	✅ 改善	格式模板发挥作用
新增问题：输出过于模板化	—	3	⚠️ 新问题	约束过强导致输出同质化

新增 Bad Case

原始内容	AI 输出	问题分析	启示
"参与策划校园活动"	所有输出都用同样的句式："通过策划XX活动，实现XX效果，参与人数XX人"	模板化严重，不同用户的输出看起来差不多	需要增加多样性和个性化
"负责实验室设备管理"	"[请补充：管理设备数量] 台设备…… [请补充：设备类型]……[请补充：维护频率]"	提示补充的标记太多，用户看了觉得"AI 没帮我什么"	补充标记要克制，只标最关键项

本轮结论

发现	影响	行动
角色设定 + 格式约束有效抑制了编造问题（5次→1次）	验证了"反编造约束"的可行性	作为所有策略的标配约束
输出模板化成为新问题（3次）	同质化输出损害用户体验	增加多样性示例和行业语境适配
4 类策略各自独立，但尚未差异化调优	策略间准确率差异未暴露	V0.3 分策略独立调优
[请补充] 标记过多引发用户负面感受	从"帮我优化"变成"让我补充"	量化补充策略需重新设计

第 3 轮：V0.3 — 策略独立调优 + 行业语境

时间：2026年2月上旬

目标：针对 4 类策略分别调优，加入行业示例和多样性引导

做法：为每类策略独立设计 Prompt，收集该策略特有的 Bad Case 并定向修复

3.3.1 STAR 改写策略 — 调优重点

核心问题： 模板化（所有输出结构一样）、无法处理"没有明显 STAR 结构"的简单描述。

调优方向：

问题	解决方案	Prompt 改动
模板化	增加 3 个不同行业（技术/产品/运营）的改写示例	在 Prompt 中加入 Few-shot 示例
简单描述过度扩展	对于简单描述（如"负责日常数据统计"），不强行套 STAR	增加降级策略："如原文无法拆分为 STAR，改用职责具体化策略"
输出同质化	增加"保留个人语言风格"指令	增加多样性约束
学生经历特殊性	科研/竞赛经历与工作经历的 STAR 结构差异大	增加学生场景的改写示例

3.3.2 关键词植入策略 — 调优重点

核心问题： 关键词植入生硬、不自然

Bad Case 示例：

- 原文："用 Excel 统计销售数据"；
- V0.2 输出："运用 Excel 进行销售数据分析，具备数据分析能力"；
- 问题："数据分析能力"关键词被生硬地贴在句尾。

调优方向：

问题	解决方案
关键词堆砌在句尾	关键词必须融入动作中而非堆砌在结尾
强行植入不适配关键词	优先植入可以自然融入的关键词，不允许植入的跳过
LLM 不理解"自然 vs 生硬"	增加反面示例（什么是生硬植入，什么是自然融入）
关键词密度控制	设置每 100 字最多植入 2-3 个关键词的上限

3.3.3 动词强化策略 — 调优重点

核心问题： 动词替换不自然、不符合中文习惯

Bad Case 示例：

- 原文："帮同事整理了数据表"；
- V0.2 输出："主导跨部门数据治理项目，协同团队成员完成数据标准化"；

- 问题：过度拔高，"帮同事整理数据"和"主导跨部门项目"差距太大。

动词强度分级表（调优后加入 Prompt）：

强度等级	示例动词	适用场景	示例
 轻度	参与、协助、配合、支持	辅助性工作、学习者角色	"参与"→"协作完成"
 中度	负责、推进、执行、完成	独立负责的工作	"负责"→"主导推进"
 重度	主导、建立、重构、驱动	从0到1或带团队的工作	"建立"→"从零搭建"

调优方向：

- 建立动词强度分级表，根据原文实际职责匹配动词等级；
- 增加"保持真实性优先于动词强度"原则；
- 对明显是大团队协作的工作，不使用"主导"等个人化动词。

3.3.4 量化补充策略 — 调优重点

核心问题：[请补充] 标记太多，用户体验差

调优方向：

问题	解决方案
标记过多（用户觉得 AI 没用）	每段最多标记 1-2 个关键数据，不是每个缺失数字都提示
无法量化内容的处理	对确实无法量化的内容（如"维护客户关系"），给出非数字的补充建议（如"维护哪些类型的客户"）
提示方式生硬	从"请补充XXX"改为"建议补充：XXX（因为YYY）"，说明理由

测试结果

指标	数据	vs V0.2
测试样本数	25 条（增加 5 条边界 case）	—
 可用	21 条 → 83%	↑ 9%
 部分可用	3 条（12%）	↓ 3%
 不可用	1 条（4%）	↓ 6%

分策略准确率（V0.3）

策略	测试数	可用	准确率	主要问题	优化优先级
STAR 改写	8	7	88%	简单描述仍偶尔被过度扩展	P2
关键词植入	6	5	83%	关键词密度高时植入顺序不优	P1
动词强化	6	5	83%	偶尔出现过度拔高	P1
量化补充	6	5	80%	建议粒度的把握仍不完美	P0

本轮结论

发现	影响	行动
准确率从 74% → 83%，策略独立调优有效	验证了"分策略精细化迭代"的思路	后续迭代按策略维度独立进行
量化补充策略准确率最低（80%），且显著低于其他策略	"何时建议量化 vs 何时接受非量化描述"的判断较难标准化	产品设计上考虑改为"AI建议+用户确认"的半自动模式
缺少 最终质量自检 环节	AI 不知道自己改得好不好，坏输出直接暴露给用户	V0.4 增加输出前自查
不同策略的改进难度差异大	影响迭代资源分配策略	后续优先攻坚量化补充（P0）

第 4 轮：V0.4 — 加入质量自检 + Few-shot 精调

时间： 2026年2月下旬 - 2026年3月

目标： 让 AI 在输出优化结果后，自行检查质量并修正明显问题；通过 Few-shot 示例精调边界 case

做法： 在每类策略的 Prompt 末尾增加"输出前自查"环节 + 加入从 Bad Case 中提炼的 Few-shot 对比示例

核心改进 1：质量自检环节

代码块

```
1  # 输出前自查（请在生成优化结果后，逐项检查，不通过则重新生成）
2  □ 1. 【真实性检查】优化后的内容是否包含了原文中没有的具体数字、项目名、团队规模？
3      → 如有，请删除并仅保留原文事实
4  □ 2. 【原创性检查】是否只是换了几个词但实质内容没有变化？
5      → 如是，请重新优化并确保有实质性改进
```

- 6 □ 3. 【可读性检查】优化后的内容是否符合中文表达习惯，读起来是否自然？
- 7 → 如不自然，请调整
- 8 □ 4. 【简洁性检查】是否加入了不必要的修饰词或套话？
- 9 → 如有，请删除
- 10
- 11 只有 4 项全部通过后，才输出最终结果。

设计思路： 借鉴代码审查（Code Review）的思想，让 LLM 在输出前"自审"，在进入用户视野前拦截低质量输出。这比事后让用户发现问题的修复成本低得多。

核心改进 2：Few-shot 示例优化

针对每类策略，从前面轮次积累的 Bad Case 中挑出 2-3 个典型案例，按"差 → 好"对照写入 Prompt：

代码块

1 # 改写示例

2

3 ❌ 差的改写：负责产品的用户调研工作 → 主导了大规模用户调研项目，通过问卷和深度访谈收集超过1000 份有效反馈

4 问题：编造数字"1000份"，原文无此数据 → 违规

5

6 ✅ 好的改写：负责产品的用户调研工作 → 通过问卷调研与深度访谈方式开展用户调研，收集用户反馈并整理分析，

7 支撑产品功能决策

8 优点：基于原文事实优化，增加了方法描述（问卷+访谈）和结果指向（支撑决策），无编造

9

10 ---

11

12 ❌ 差的改写：用 Excel 做数据统计 → 运用 Excel 进行数据统计分析

13 问题：换说法但没实质改变，属于"无效改写" → 违规

14

15 ✅ 好的改写：用 Excel 做数据统计 → 使用 Excel 处理销售数据，通过数据透视表分析月度趋势并输出统计报告

16 优点：基于"数据统计"合理扩展，补充了工具（数据透视表）、对象（销售数据）、产出（统计报告）

测试结果

指标	数据	vs V0.3
测试样本数	25 条	—
✅ 可用	22 条 → 89%	↑ 6%

⚠️ 部分可用	2 条 (8%)	↓ 4%
❌ 不可用	1 条 (4%)	→ 持平

分策略准确率 (V0.4)

策略	测试数	可用	准确率	vs V0.3	变化分析
STAR 改写	8	7	88%	→ 持平	接近天花板，继续提升需要更细分的场景模板
关键词植入	7	6	86%	↑ 3%	Few-shot 对比示例有效
动词强化	5	5	100%	↑ 17%	质量自检大幅抑制了"过度拔高"
量化补充	5	4	80%	→ 持平	策略本身的主观性导致难以进一步提升

关键洞察： 动词强化策略提升最大 (+17%)，质量自检有效抑制了"过度拔高"问题。量化补充策略连续两轮持平在 80%，说明纯 Prompt 优化已到瓶颈，需要产品形态层面的改动（改为人机协作模式）。

残留问题（已知但本轮未解决）

问题	出现频率	根因	计划	预期解决手段
量化补充的粒度判断	20% (1/5)	"该不该提示量化"是主观判断，难以规则化	V1.0 上线后利用用户反馈数据训练分类器	产品机制 > Prompt 优化
STAR 改写对非传统经历的处理	12% (1/8)	科研/竞赛类经历与工作经历的 STAR 结构差异大	V1.1 增加"科研经历"和"竞赛经历"专属模板	Prompt 模板 + Few-shot
Few-shot 示例的维护成本	—	每轮新增 Bad Case 需要人工筛选和编写对比示例	建立 Bad Case 知识库，定期批量更新	流程建设

四、全量样本准确率趋势

4.1 整体趋势

代码块



4.2 不可用率趋势



4.3 分策略趋势对比

策略	V0.3	V0.4	提升	提升空间判断
STAR 改写	88%	88%	0%	接近天花板，需场景细分突破
关键词植入	83%	86%	+3%	中等提升空间
动词强化	83%	100%	+17%	已达到天花板
量化补充	80%	80%	0%	瓶颈在策略本身，需要产品形态创新

五、策略横向对比

5.1 策略难度矩阵

	准确率天花板	Prompt 优化难度	问题根源	推荐模式
STAR 改写	~90%	★★★ 中等	部分经历天然不适配 STAR 结构	全自动 + 降级兜底
关键词植入	~90%	★★★ 中等	"自然融入"的判断主观	全自动 + 密度控制
动词强化	~95%	★ 低	已有明确规则（动词分级表）	全自动
量化补充	~80%	★★★★ 高	"何时该量化"难以规则化	人机协作

5.2 策略适用场景矩阵

策略	实习经历	项目经历	校园活动	技能描述	自我评价
STAR 改写	最佳	最佳	⚠️ 部分适用	不适用	不适用
关键词植入	适用	适用	⚠️ 谨慎	最佳	适用
动词强化	适用	适用	适用	适用	⚠️ 部分适用
量化补充	最佳	最佳	⚠️ 部分适用	⚠️ 部分适用	不适用

六、关键经验总结

6.1 核心发现

发现	详细说明	对产品的影响
"不编造"是底线，也是最难的约束	LLM 天然倾向"把话说满"，不加约束就会编造数字。4 轮迭代中，"编造事实"从 5 次降到 0 次，是所有改进中成本最高的	所有 Prompt 第一条就是严禁编造；产品设计上宁可多缺数据也不能编

5			
6		Layer 2: 核心原则 – "哪些绝对不能做"	
7		├─ 严禁事项 (如"不得编造数据")	
8		├─ 优先级原则 (如"真实性 > 专业性")	
9		└─ 降级策略 (做不好时的兜底方案)	
10			
11		Layer 3: 任务描述 – "要做什么"	
12		├─ 核心任务	
13		└─ 边界条件 (什么不处理)	
14			
15		Layer 4: Few-shot 示例 – "好 vs 差"对比	
16		├─ 好的示例 (标注为什么好)	
17		└─ 差的示例 (标注为什么差、违反了什么规则)	
18			
19		Layer 5: 输出格式 – "怎么呈现"	
20		├─ 结构化模板	
21		└─ 格式约束 (长度、结构、标记)	
22			
23		Layer 6: 质量自检 – "先自查再输出"	
24		├─ 逐项检查清单	
25		└─ 不通过则重新生成	
26			

7.2 Prompt 迭代 SOP

代码块			
1	1.	Baseline 测试	
2		└─ 用最小 Prompt 建立准确率基线, 看清 LLM 的"裸行为"	
3			
4	2.	Bad Case 收集	
5		└─ 从基线测试中收集至少 10 个典型 Bad Case, 分类标注问题类型	
6			
7	3.	问题归因	
8		└─ 每个 Bad Case 问 3 个问题:	
9		- 是什么问题? (编造/无效/生硬/模板化...)	
10		- 什么原因? (Prompt 缺约束 / LLM 倾向 / 任务本身难...)	
11		- 什么解法? (加约束 / 加示例 / 改策略设计 / 改产品机制)	
12			
13	4.	定向修复	
14		└─ 针对归因结果修改 Prompt, 每次只改 1-2 个变量以便归因效果	
15			
16	5.	回归测试	
17		└─ 用同一批样本 + 新增边界样本测试, 对比准确率变化	
18			

7.3 何时停止 Prompt 优化

判断标准	本项目实际情况
边际收益 < 5% 且连续 2 轮	⚠ 量化补充已触发 (80%→80%)
单个策略准确率 > 90% 或连续持平	✅ 动词强化 (100%)、STAR 改写 (88%持平)
剩余问题根因不在 Prompt 而在产品机制	⚠ 量化补充的"粒度判断"主观性问题

结论：对于量化补充策略，继续优化 Prompt 的 ROI 已经很低，应转向产品形态创新（如"AI建议 + 用户确认"的半自动模式）。

八、成本分析

8.1 Token 消耗估算

版本	平均输入 Token	平均输出 Token	单次优化总 Token	vs V0.1 增长
V0.1	~200	~300	~500	—
V0.2	~500	~400	~900	+80%
V0.3	~800	~500	~1,300	+160%
V0.4	~1,200	~600	~1,800	+260%

说明：Token 消耗与 Prompt 长度正相关。V0.4 的 Prompt 长度是 V0.1 的 6 倍，但准确率提升了 27 个百分点。在 AI 产品中，Prompt 长度是"投资"而非"成本"——更长的 Prompt 换取更高的输出质量，从而减少用户的修改成本。

8.2 成本-收益分析

指标	V0.1	V0.4	变化
单次优化 Token	~500	~1,800	+260%
可用率	62%	89%	+43.5%

不可用率	15%	4%	-73%
用户预期修改次数（不可用时）	~3 次	~1 次	-67%

单位质量成本： V0.1 每获得 1% 可用率消耗 ~8 Token；V0.4 每获得 1% 可用率消耗 ~20 Token。但用户端节省的修改时间远超 Token 成本增长。

九、Prompt 维护与监控体系

9.1 持续监控指标（V1.0 上线后）

指标	监控方式	告警阈值	响应动作
用户采纳率（直接使用 / 微调后使用 / 放弃）	前端埋点	< 70% 直接采用	复查对应策略 Prompt
优化后二次修改率（用户手动修改 AI 输出的比例）	编辑行为追踪	> 40%	检查是否存在"无效改写"问题
策略使用分布（4 类策略的使用频次）	功能打点	某策略 < 10%	评估是否该策略需求弱或体验差
Bad Case 上报率（用户投诉/低分反馈）	反馈入口	> 5%	触发 Prompt 紧急修复流程
单次优化平均耗时	API 监控	> 10s	检查 Prompt 是否过长导致推理变慢

9.2 Prompt 版本管理规范

代码块

```
1  Prompt 版本管理规则：
2  |—— 每类策略独立版本号（如 STAR_v1.2.0）
3  |—— 版本号规则：主版本.次版本.修订号
4  |   |—— 主版本：策略逻辑重大变更（如全自动→半自动）
5  |   |—— 次版本：Few-shot 示例增删、自查清单调整
6  |   |—— 修订号：措辞微调、示例修正
7  |—— 每次修改记录：修改人、修改内容、修改原因、预期效果
8  |—— 保留最近 3 个版本的 Prompt 快照，支持快速回滚
```

9.3 Bad Case 知识库建设

代码块Bad Case 知识库结构：

- 2
- 3
- 4
- 5
- 6
- 7
- 问题分类：编造事实 / 无效改写 / 模板化 / 过度拔高 / 生硬植入 / 其他
- 严重程度：P0（不可用） / P1（部分可用） / P2（可用但有瑕疵）
- 关联策略：STAR 改写 / 关键词植入 / 动词强化 / 量化补充
- 关联岗位：技术 / 产品 / 运营 / 设计
- 原始内容 + AI 输出 + 问题分析 + 修复方向
- 是否已转化为 Few-shot 示例：是 / 否

十、后续优化计划

阶段	时间	优化方向	预期手段	预期提升	优先级
V0.5	上线前	针对边界场景补充 15 条测试样本	邀请 3 名不同专业同学提供极端 case	样本覆盖度 ↑ 30%	P0
V0.5	上线前	量化补充策略引入"置信度"标记	对不确定的建议标注"AI 建议，请确认"	用户体验 ↑	P0
V1.0	上线后1月	根据用户采纳率数据，识别低准确率场景	埋点数据 → 定向优化	真实场景准确率摸底	P0
V1.0	上线后1月	建立 A/B 测试框架，支持 Prompt 变体对比	分流测试	数据驱动迭代能力	P1
V1.1	上线后2月	"量化补充"策略引入用户协作模式	AI 标记建议补充的位置 → 用户手动填入 → AI 重新整合	量化补充准确率 80% → 85%	P0
V1.1	上线后2月	新增"科研经历"和"竞赛经历"专属 Prompt 模板	针对学生群体高频场景专项优化	STAR改写 88% → 90%	P1
V1.2	上线后3月	引入用户偏好学习	记录用户采纳/拒绝的行为模式，个性化调整输出风格	用户满意度 ↑	P2
V2.0	上线后6月	基于用户反馈数据 fine-tune 专用模型	积累 1000+ 采纳样本后评估微调可行性	准确率 89% → 92%+	P2
V2.0	上线后6月	多语言简历优化（英文简历）	复用 Prompt 方法论，适配英文语境	用户群扩展	P2

